그래프 신경망 기반 사기 탐지의 조건적 유효성 : 시간적 데이터 누수 통제 환경에서의 실증 분석

Conditional Effectiveness of GNN-based Fraud Detection under Temporal Data Leakage Control

요 약

그래프 신경망(GNN) 기반 사기 탐지 연구들은 관행적인 무작위 데이터 분할을 사용하여 미래 정보가 과거 노드 평가에 개입되는 시간적 오류를 빈번하게 내포하고 있다. 본 연구는 시계열이 통제된 OOT(Out-of-Time) 롤링 검증을 통해 미래 정보 유입을 차단하였으며, 무작위 분할에서 관측되는 같은 작성자 관계의 기여 중 약 28%가 의사 성능(Spurious Performance)임을 정량적으로 규명하였다. 나아가 순수 위상(Topology) 기여도를 분석한 결과, 과거 이력을 보유한 리뷰에서는 관계 정보가 탐지 성능을 유의미하게 증폭시킨 반면, 이력이 없는 리뷰에서는 관계 정보의 기여가 거의 나타나지 않았다. 또한 필터링 리뷰가 다수의 비필터링 리뷰와 연결되는 이질성(Heterophily)이 높은 관계에서는 이웃 집계가 신호를 희석시켜 오히려 탐지 성능이 하락하였다. 결론적으로 본 연구는 GNN의 무조건적 유효성을 반박하기보다 관계 정보가 유효한 조건을 실증적으로 제시하며, 이력 미보유 리뷰의 구조적 한계와 이질성 노이즈를 고려한 조건부 아키텍처로 사기 탐지 시스템이 진화해야 함을 제언한다.

1. 서 론

온라인 리뷰는 소비자의 구매 결정과 플랫폼의 신뢰를 좌우하며, 조작된 리뷰는 소비자를 오도하고 정상 사업자의 공정한 경쟁을 저해한다. 이를 탐지하기 위해 리뷰·작성자·상점 사이의 관계를 그래프로 구성하고 그래프 신경망(GNN)으로 학습하는 연구가 주류를 이루어 왔다[1,2,3].

그러나 이들 연구가 보고하는 관계 정보의 기여에는 검증되지 않은 두 가지 전제가 내재되어 있다. 첫째, 평가 과정에서 시간 순서가 보장되지 않는다. 리뷰를 무작위로 분할하여 학습·평가하면서 같은 작성자 관계(R-U-R)를 이용하면, 평가 대상보다 나중에 작성된 같은 작성자의 리뷰가 학습 그래프에 포함된다. 즉, 실제 운영 환경에서는 활용할 수 없는 미래 정보가 관계 정보의 기여로 계산된다. 둘째, 관계 정보가 모든 리뷰에 고르게 유효하다고 가정한다. 같은 상점 기반 관계는 다수 이웃과 연결되나 그 대부분이 비필터링 리뷰이므로 동질성(Homophily) 가정이 성립되기 어려우며, 과거 이력이 없는 작성자의 리뷰에는 참조할 같은 작성자 이웃이 존재하지 않는다.

이에, 본 연구는 시간적 누수를 통제한 환경에서 관계 정보가 리뷰 사기 탐지에 기여하는 조건적 유효성을 실증하고자 한다. 이를 위해, YelpZip 2014년 리뷰 180,659건에 대해 피처·이력구분·그래프 연결을 모두 작성 시점까지의 정보로만 재구성하고 시간 순서로 평가해 이를 통제한 뒤, 관계 정보의 기여를 그래프를 사용한 모델과 동일 피처·무그래프 모델의 PR-AUC 차이로 측정하였다.

본 연구의 기여는 다음 세 가지로 요약할 수 있다. (1) 피처·그래프·이력 구분을 모두 작성 시점까지의 정보로 재구성한 시간 순서 평가 체계를 설계하고, 무작위 분할에서 관측되는 같은 작성자 관계의 기여 중 28%가 미래 정보의 유입에 기인함을 정량화하였다. (2) 누수를 통제한 환경에서 관계 정보의 기여가 성공·실패·한계의 세 조건으로 구분됨을 보이고, 그 원인을 이웃의 라벨 구성으로 설명하였다. (3) 필터링 리뷰의 약 82%가 관계 정보의 기여가 미미한 이력 미보유 구간에 속함을 밝혀, 관계 정보를 조건에 따라 선택적으로 적용해야 할 근거를 제시하였다.

본 연구는 이력 미보유 리뷰의 구조적 한계와 이질성 노이즈를 고려하여 조건부 아키텍처로 사기 리뷰 탐지 시스템의 진화 방향을 제언한다.

2. 선행 연구

리뷰 사기 탐지의 대표적 GNN 모델들은 공통적으로 리뷰(노드)를 무작위로 층화 분할하여 평가한다. CARE-GNN[1]과 BWGNN[3]의 공개 구현은 리뷰 노드의 층화 무작위 분할을 사용한다. 이러한 평가는 주어진 그래프의 미분류 노드를 예측하는 성능을 측정하지만, 작성 시점 이후의 자료를 사용할 수 없는 미래 리뷰 탐지와는 조건이 다르다. 본 연구는 작성일이 포함된 YelpZip을 사용하여 시간 순서 평가에서 관계 정보의 기여를 측정한다.

이웃 관계의 품질은 기존 리뷰 탐지 연구에서도 다루어졌다. CARE-GNN[1]은 관계 위장에 대응하는 이웃 선택을, BWGNN[3]은 이상 탐지를 위한 대역 통과 필터를 사용하며, Wang 등[4]은 낮은 동질성 환경에서 라벨 정보를 활용한 집계를 제안한다. 본 연구는 이러한 구조 개선과는 다른 관점에서, 범용 GraphSAGE를 고정하고 리뷰 작성자의 이력 유무와 관계 유형별 성능 차이를 종합적으로 분석한다.

3. 연구 방법론 및 데이터 통제

3.1 데이터 수집

YelpZip[5]의 2014년 리뷰 180,659건을 사용하며, 이 중 Yelp 필터링 리뷰는 12.7%이다. 선행 연구가 주로 사용하는 YelpChi 공개본은 리뷰 작성 시각을 포함하지 않아 시간 순서 분할이 불가능하므로, 같은 저자가 수집하고 작성일을 포함하는 YelpZip을 사용한다. 필터 결과는 실제 사기 여부를 확정하는 정답이 아닌 대리 라벨로 취급한다. 이하 두 클래스를 필터링 리뷰와 비필터링 리뷰로 지칭한다. 자세한 기초 데이터 통계는 표 1과 같다.

표 1. 기초 데이터 통계

항목	YelpZip 전체	분석 대상(2014년)
리뷰 수	608,458	180,659
작성자 수	260,239	101,729
상점 수	5,044	4,529
기간	2004.10~2015.01	2014.01~2014.12
필터링 리뷰	80,439 (13.2%)	22,864 (12.7%)
평균 평점	3.92	3.95
4~5점 비율	73.4%	74.0%
길이(중앙값)	462자	406자
이력 미보유형	-	89,530
이력 보유형	-	91,129

3.2 시간적 데이터 누수 통제와 OOT(Out-of-Time) 롤링 검증

본 연구는 미래 정보의 유입을 차단하기 위해 2014년 YelpZip 데이터셋(180,659건)에 대하여 10~12월 3회 분할 OOT 롤링 검증을 도입하였다. 분석 결과, 기존의 무작위 분할 방식에서 얻어진 성능 향상분(ΔPR-AUC)의 약 28%(구간 [4%, 50%])가 미래 정보 유입에 의한 의사 성능임을 정량화하였다. 이는 과거의 이력만을 참조할 수 있는 실제 운영 환경에서 기대할 수 있는 성능에 더 가까운 추정치이다.

3.3 대조군 설계: 이력 미보유형 및 보유형 집단

과거 위상(Topology) 정보의 존재 여부가 그래프 모델에 미치는 영향을 평가하기 위해, 리뷰를 과거 이력이 전무한 '이력 미보유형(콜드 스타트)' 집단과 이력을 보유한 '이력 보유형' 집단으로 조작적 정의(Operational Definition)를 통해 실험을 통제하였다. 각각 89,530건과 91,129건이며, 필터링 비율은 20.9%와 4.6%이다. 단, 날짜 내 순서를 알 수 없으므로 최초관측일의 리뷰는 모두 미보유형으로 분류한다. 이 구분은 관측 이력에 대한 것으로 실제 계정 생성 시점을 의미하지 않는다.

3.4 관계와 노드 피처

관계는 같은 작성자(R-U-R), 같은 상점·같은 평점(R-S-R), 같은 상점·같은 달(R-T-R)로 구성한다. 각 리뷰는 시간상 선행하는 리뷰로부터만 정보를 전달받도록 연결하고, 리뷰 작성 시점까지 이용 가능한 정보로 노드 피처를 구성한다. 피처는 Rayana와 Akoglu[5]의 정의를 바탕으로 구성한 리뷰·작성자·상점 관련 37개이다. 두 모델에 동일한 피처를 입력하므로 성능 차이는 기존 피처에 대한 관계 집계의 추가 기여로 해석한다.

3.5 백본(Backbone) 채택과 평가

백본(Backbone)은 자기 피처와 이웃 집계를 별도로 처리하는 GraphSAGE[6]이다. 관계 효과를 같은 구조에서 비교하기 위해 단일 백본을 사용하고, 동일 피처의 무그래프 모델을 대조군(Baseline)으로 둔다. 관계 정보의 기여는 ΔPR-AUC = PR-AUC(그래프) − PR-AUC(무그래프)로 정의한다. 양의 값은 집계 후 성능 향상을, 음의 값은 성능 저하를 의미한다. 평가는 학습 구간을 확장하는 세 번의 시간 순서 분할로 수행한다. 학습·검증·평가 구간은 각각 1-8월·9월·10월, 1-9월·10월·11월, 1-10월·11월·12월이다. 검증 구간으로 조기 종료를 결정하고 모델별 학습을 5회 반복한다. 그래프 모델과 무그래프 모델의 동일 평가 리뷰를 대응시킨 부트스트랩으로 ΔPR-AUC의 95% 신뢰구간을 산출한다.

4. 실험 결과

표 2. 이력유무·관계 유형별 관계 정보의 기여

이력	조건	관계	ΔPR-AUC	95% 신뢰구간
보유	성공	R-U-R	+0.110	[+0.089, +0.133]
	실패	R-S-R	-0.025	[-0.037, -0.015]
		R-T-R	-0.035	[-0.047, -0.022]
미보유	한계	R-U-R	-0.005	[-0.010, 0.000]
		R-S-R	+0.009	[+0.002, +0.015]
		R-T-R	+0.006	[0.000, +0.012]

4.1 실증 분석 결과: 조건부 비대칭성

표 2와 그림 1에 나타난 바와 같이, GNN의 위상적 기여도는 작성자의 과거 이력 유무와 관계 유형(Edge)의 특성에 따라 뚜렷하게 구분되는 세 가지 조건적 유효성을 보였다(그림 1의 회색은 신뢰구간이 0을 포함).

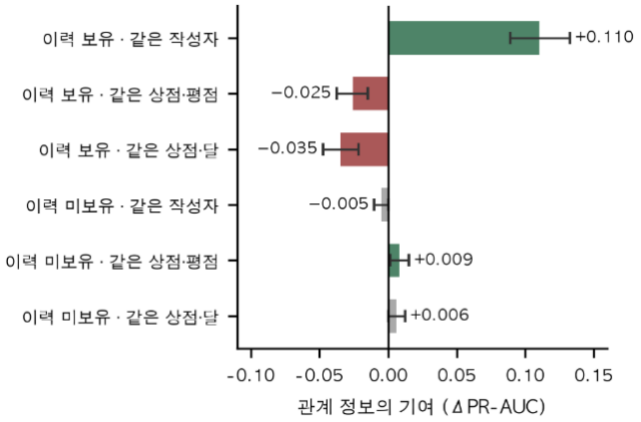


그림 1. 이력·관계별 관계 정보의 기여(95% 신뢰구간)

성공 조건 (과거 이력 앵커 효과): 이력 보유형 리뷰에 같은 작성자 관계를 적용하였을 때, 관계 정보의 기여는 +0.110(95% 신뢰구간 [+0.089, +0.133])으로 가장 컸다. 이는 이력 보유

작성자의 과거 리뷰가 앵커 역할을 수행하여, 동질성 기반의 과거 이력의 일관성이 증폭될 때 GNN이 가장 유효함을 보여준다.

실패 조건 (위장 및 이질성의 평활화 역효과): '같은 상점·평점'이나 '같은 상점·달' 관계를 적용했을 때, 모델의 성능은 오히려 하락(-0.025, -0.035)하였다. 같은 상점 기반 관계에서는 필터링 리뷰의 이웃 중 약 83%가 비필터링 리뷰였으며(필터링 이웃 비율 R-S-R 17.4%, R-T-R 17.5%), 이는 비필터링 리뷰의 이웃 구성(9.7%, 10.8%)과 큰 차이가 없었다. 이러한 이질성(Heterophily)이 높은 환경에서는 GNN의 이웃 집계가 소수의 필터링 신호를 다수의 비필터링 이웃 피처와 섞어 희석시키는 평활화(Smoothing)로 작용하는 것으로 해석된다.

한계 조건 (이력 미보유 집단의 구조적 고립): 과거 이력이 전무한 '이력 미보유형(콜드 스타트)'에서는 같은 작성자의 과거 리뷰가 존재하지 않아 같은 작성자 관계의 기여가 관측되지 않았다(-0.005). 이력에 의존하지 않는 상점 기반 관계는 +0.009, +0.006으로 작은 기여를 보였으나, 성공 조건의 약 1/12 수준에 그쳤다. 즉 상점 관계는 작성자 이력을 대체하지 못하며, 이는 이력 미보유 구간의 구조적 한계(Structural Limitation)이다.

4.2 평점 이탈에 따른 기여 차이

이력 보유형에 R-U-R을 적용했을 때, 평점 비이탈 리뷰의 기여는 +0.123 [+0.100, +0.145], 이탈 리뷰의 기여는 +0.038 [+0.005, +0.072]이었다. 두 집단의 기여 차이도 +0.085 [+0.044, +0.123]로 통계적으로 유의하였다. 즉 작성자 관계가 사용 가능한 경우에도 추가 기여의 크기는 리뷰 특성에 따라 달랐다.

평점 이탈 집단은 비이탈 집단보다 필터링 비율이 높았지만(5.98% 대 4.62%), 무그래프 PR-AUC는 낮았다(0.153 대 0.203). 따라서 이탈 집단의 작은 기여를 기본 피처만으로 이미 충분히 탐지되기 때문이라고 설명하기는 어렵다. 기여 차이의 원인을 구분하려면 집단별 이력량과 이웃 구성에 대한 후속 분석이 필요하다.

4.3 미래 리뷰 제거에 따른 변화

표 3. 무작위 분할의 자료 제거 실험

학습 데이터 조건	기여(ΔPR-AUC)
A. 원본(무작위 분할)	+0.129
B. 평가 대상 작성자의 미래 리뷰 제거	+0.093
C. 평가 대상 작성자의 리뷰 전체 제거	+0.001

이력 보유형의 R-U-R에 대해 무작위 분할의 평가 집합 15%를 고정한 후, 학습 자료에서 평가 대상 작성자의 미래 리뷰 또는 모든 리뷰를 제거하였다(표 3). 이 분석은 최초 관측일 리뷰의 재분류(4.4) 이전의 집단 정의를 사용하므로 표 2와 절대값을 직접 비교하지 않는다. 대응 부트스트랩으로 추정한 미래 리뷰 제거 전후의 추가 기여 차이는 +0.035 [+0.005, +0.068]이며, 원래 추가 기여의 약 28%에 해당한다(구간 [4%, 50%]). 이는 해당 제거 실험에서 미래 자료 포함 여부에 따라 추가 기여가 달라졌음을 보여준다.

작성자 리뷰 전체를 제거한 C와 같은 규모로 학습 자료를 무작위로 40% 줄였을 때는 추가 기여가 17% 감소하였다. 이 대조 결과는 제거 대상의 구성이 중요함을 시사한다. 다만 자료 제거는 학습 집합과 관계 구조를 함께 바꾸므로, A-B와 B-C를 미래 정보와 과거 이력의 순수한 인과 효과로 해석하지 않는다.

4.4 동일 날짜 처리에 대한 민감도

최초 관측일의 리뷰를 모두 이력 미보유형으로 재분류하면, 보유형의 R-U-R 기여는 +0.065에서 +0.110으로 증가하였다. R-S-R과 R-T-R은 각각 -0.011에서 -0.025, -0.022에서 -0.035로 변화하였다. 이 비교에서 관계별 기여의 방향(부호)은 유지되었으나, R-U-R의 효과 크기는 약 70% 변화하였다. 따라서 방향의 일관성과 효과 크기의 민감성을 구분해야 하며, 이 변화는 집단 구성의 변경을 포함한다.

5. 결론 및 향후 연구

본 연구는 시간적 데이터 누수를 통제한 환경에서 GNN 기반 사기 탐지의 관계 정보 기여가 보편적이지 않고, 과거 이력의 유무와 이웃 관계의 동질성에 따라 성공·실패·한계 세 조건으로 구분됨을 실증하였다. 이력 보유형에서는 작성자 관계가 큰 기여를 보였지만 상점 관계는 성능을 저하시켰다. 이력 미보유형에서도 상점·평점 관계의 작은 기여가 관측되었다. 또한 이력 보유형 내부에서 평점 이탈 여부에 따라 기여의 크기가 달랐다. 이 결과는 관계를 일괄 적용하기보다 대상 리뷰의 이력 가용성과 관계별 검증 결과를 함께 고려할 필요성을 뒷받침한다. 나아가, 본 연구 결과는 관계 정보를 언제 어떻게 적용해야 하는지에 대한 사용 지침으로 활용될 수 있다.

향후 사기 탐지 시스템은 데이터의 위상적 한계와 이질성을 동적으로 인지하는 '맥락 인식형(Context-Aware) 조건부 하이브리드 아키텍처'로 발전할 필요가 있다. 이력이 없는 콜드 스타트 리뷰에는 관계 정보 대신 피처 기반 앙상블을 우선 적용하고, 이력 보유 리뷰 중 이웃 구성이 이질적인 관계에서는 평활화를 고려하여 1-hop 구조를 넘어 멀티홉 또는 스펙트럴 계열 GNN[3]을 검토할 필요가 있다.

참고문헌

[1] Y. Dou, Z. Liu, L. Sun, Y. Deng, H. Peng, and P. S. Yu, "Enhancing graph neural network-based fraud detectors against camouflaged fraudsters," ACM CIKM, 2020.

[2] Y. Liu, X. Ao, Z. Qin, J. Chi, J. Feng, H. Yang, and Q. He, "Pick and choose: A GNN-based imbalanced learning approach for fraud detection," WWW, 2021.

[3] J. Tang, J. Li, Z. Gao, and J. Li, "Rethinking graph neural networks for anomaly detection," ICML, 2022.

[4] Y. Wang, J. Zhang, Z. Huang, W. Li, S. Feng, Z. Ma, Y. Sun, D. Yu, F. Dong, J. Jin, B. Wang, and J. Luo, "Label information enhanced fraud detection against low homophily in graphs," WWW, 2023.

[5] S. Rayana and L. Akoglu, "Collective opinion spam detection: Bridging review networks and metadata," ACM SIGKDD, 2015.

[6] W. L. Hamilton, R. Ying, and J. Leskovec, "Inductive representation learning on large graphs," NeurIPS, 2017.